开发说明文档

DDH 超声图像智能裁剪与协作审核系统

参赛赛道：智能医学创新应用赛

参赛队伍信息

序号	专业	年级	学历层次
队员 1	计算机科学与技术	2024 级	本科生
队员 2	计算机科学与技术	2024 级	本科生
队员 3	软件工程	2025 级	本科生

2026 年 11 月

摘　要

婴儿髋关节超声是发育性髋关节发育不良（DDH）早期筛查的主要手段，临床依据 Graf 法在标准切面上测量 α、β 角[1]。而在这之前，必须先从超声设备导出的整屏截图中裁出纯成像区——四周黑边、设备参数栏与深度标尺都会被后续算法误读。目前这一步仍靠人工完成。本文面向该环节，设计并实现了一套全自动裁剪系统，**设计目标是让 Graf 分型的输入准备过程高度自动化**。

系统采用**两阶段**架构：第一阶段用规则几何算法定位成像窗口（内容掩膜、形态学滤波、连通域、黑走廊判据与像素级梯度吸附），**无需训练数据**；第二阶段用 CropNet 在窗口内回归上下边界，取 ResNet-18 的 layer3 输出以保留纵向分辨率[2]，经 ROIAlign[3] 压成行向量后做一维行卷积，以累积 softmax 从结构上保证上下有序。

我们在同一比较集（88 张）上系统比较了 **6 组网络配置**。结果表明：**更换主干或加深层级均未带来统计显著的精度提升**——ResNet-50 参数量 2.09 倍、CPU 耗时约 2.5 倍，纵向 IoU 仅从 0.9096 变到 0.9130（$p = 0.2165$）。据此确定 **ResNet-18 + Layer3** 为生产方案；而融合 Layer1–3 在理论上应更优，实测把 3% 合格率从 51.1% 提到 56.8%，虽未达显著（$p = 0.3323$），已列为下一步。对照实验还显示，标注口径统一带来的收益（上边界误差**中位数** 89 px $\rightarrow$ 17.5 px，下降 80%）远超任何网络结构改动。

关于选型的独立性：各组**只用验证集（128 张）早停与选点**，测试集不参与训练过程；**但"6 组中选哪一组作为生产方案"这一决定，是看过这 88 张的对比结果后作出的**。故该 88 张在结构对比问题上应视为**模型比较集**：其上差异检验仍是有效的配对比较（各组评估于同一批图像），但**不宜再当作已选模型的无偏泛化估计**。校准集（86 张）用于阈值标定，未参与结构对比。

效率方面，本组 3 名成员手工裁剪 10 张平均耗时 153.1 s（15.3 s/张），本系统 CPU 端到端 **199 ms/张，单张提速约 77 倍**。

关键词：发育性髋关节发育不良；超声图像；自动裁剪；ResNet-18；层选择；消融实验

1 项目背景与设计目标

1.1 临床背景：从超声图像到 Graf 分型

发育性髋关节发育不良（Developmental Dysplasia of the Hip, DDH）是婴幼儿最常见的骨骼肌肉系统疾病之一，及早发现并干预可显著降低远期残疾风险。我国诊疗指南将超声列为 6 月龄以内婴儿的首选筛查手段[4]。

临床判读依据 **Graf 法**[1]：在髋关节冠状面标准切面上，以髂骨外缘为基准线，测量骨性髋臼顶角 α 与软骨性髋臼顶角 β。α **角是分型的主要依据**（$\alpha \geqslant 60°$ 为 I 型成熟髋，$\alpha < 43°$ 归入脱位侧），但**完整分型还须结合 β 角、骨缘形态（如 IIa/IIb 需按月龄区分）与盂唇覆盖情况**，不能仅凭单一角度判定。**这一分型的精度直接依赖图像质量与测量基准的稳定**。

1.2 问题所在：Graf 分型之前的”准备工作”往往被忽视

超声设备导出的整屏截图并不等于可用于测角的图像。它四周是设备黑边，左侧印有设备参数栏（频率、增益、深度），右侧印有深度标尺，部分图像还带有体位示意图。这些内容会干扰后续的自动测角算法。

因此，**Graf 分型前必须先把纯成像区裁出来**。而这一步目前仍由人工完成。图 1 给出了完整的三段式对照：

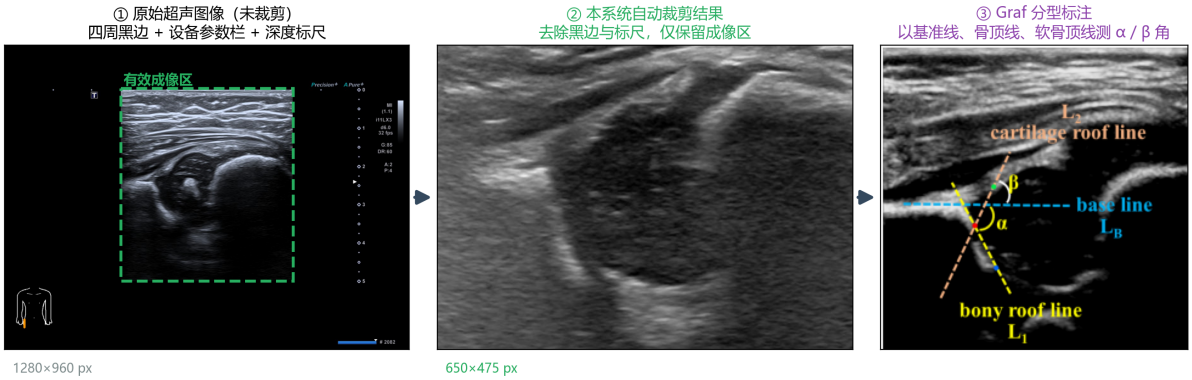


图 1 设计目标：把① → ②这一步自动化，为③的 Graf 分型提供干净输入。左：设备导出的整屏截图；中：本系统自动裁剪结果；右：Graf 分型所需的三条标准线与 α/β 角——以基准线（base line, L_B）为参照，测量骨顶线（bony roof line, L_1）与软骨顶线（cartilage roof line, L_2）所夹锐角[1]

本项目的定位很明确：我们不解决③（Graf 分型诊断），我们解决① → ②这一步——**让进入分型环节的图像是干净、规范、口径一致的**。

1.3 国内外研究现状：这一环节尚属空白

为确认该环节是否已有成熟方案，我们系统检索了 DDH 领域的 AI 研究。Bhavsar 等 2025 年的系统综述纳入了 **23 项** DDH 人工智能研究[5]，其中 15 项针对髋关节超声（合计 8 315 张）、8 项针对骨盆 X 线片（7 091 张），报告 AUC 在 0.80–0.99 之间。这些工作集中在**分型、测角、标准切面识别**等下游任务上，**我们未检索到专门针对”成像区裁剪”这一前置环节的系统性工作**。该综述亦将”图像质量优化与自动化”列为未来方向。

注：此处表述为”未检索到”，而非”不存在”。检索范围限于 *PubMed / Web of Science* 主要索引中可获取的英文与中文文献。

1.4 设计目标

基于上述背景，本项目确立三个层次的目标：

1. **自动化**：把”从整屏截图裁出纯成像区”这一人工步骤，变为一次文件夹导入即可完成的自动流程；
2. **规范化**：所有图像采用统一的裁剪口径，消除人工之间的判断差异，为后续测角提供一致基准；
3. **轻量化**：在普通办公电脑（无独立显卡）上即可运行，单张耗时控制在秒级以下。

1.5 效率对比：量化人工与自动的差距

为量化上述目标的实际价值，我们做了人工与本系统两组对照。

人工裁剪：本组 3 名成员，每人使用 Windows 自带”画图”软件手工裁剪 10 张，从打开第一张到全部保存完毕计时。三名被试的原始记录与单张平均如下：

被试	原始记录	折算秒	单张平均
第 1 人	2 分 34 秒 96	154.96	15.50
第 2 人	2 分 20 秒 78	140.78	14.08
第 3 人	2 分 43 秒 45	163.45	16.35
	人均	**153.06**	**15.31**

表 1　三名成员人工裁剪耗时（每人 10 张，Windows 画图）

本系统：测试平台为**联想拯救者 Y7000P 笔记本**，搭载 Intel Core i7 处理器与 **NVIDIA GeForce RTX 4060 Laptop（8 GB 显存）**，内存 16 GB，运行 Windows 11，全程离线。端到端耗时（含黑边去除、窗口定位、边界预测与保存）实测 **CPU 199.31 ms/张**、**GPU 66.93 ms/张**。
也就是说，人工一人的单张耗时（15.31 s）相当于本系统 CPU 端 **77 张**的处理时间。按 400 张计，人工约需 **102 分钟**，本系统只需 **1.3 分钟**。

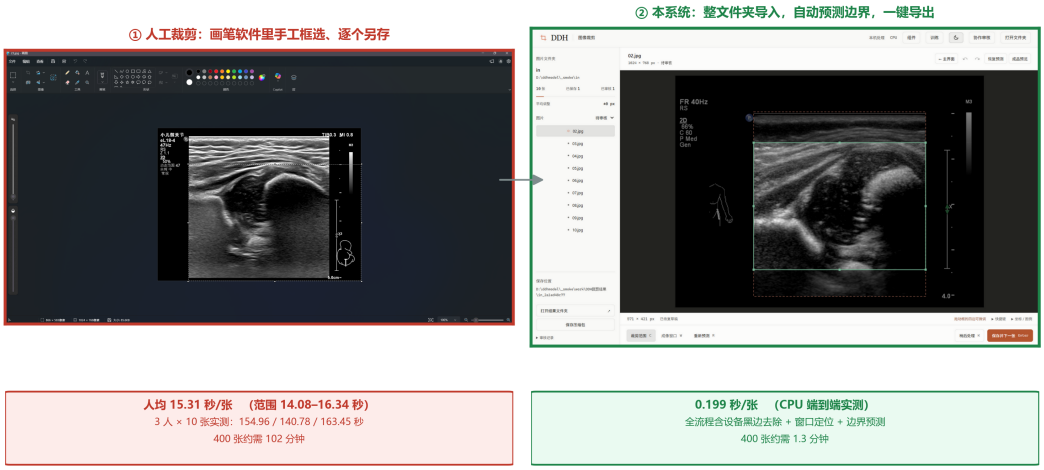


图 2　人工裁剪与本系统自动出图的效率对比。左为手工在” 画图” 软件中框选并逐个另存；右为本系统整文件夹导入、自动预测边界、一键导出

值得注意的是，**人工耗时的主体并不在” 拖框” 本身**。在” 画图” 里拖出一个框通常不到 10 秒，真正把时间拉长的是**打开图片、保存结果、再去找下一张**这一整套操作——它们不涉及任何判断，却是逐张处理无法回避的部分。手工流程必须一张一张地重复这些步骤，而本系统的批量模式把它们整体消掉：**77 倍的差距不是来自” 框得更快”，而是来自” 不需要逐张框”**。

2　技术方案

2.1　总体设计思想：为什么是两阶段

一个直觉的方案是” 用一个检测网络直接框出成像区”。我们没有采用，原因在于**两类误差的量级完全不同**：

- **左右边界**由黑边决定，几乎是确定的几何量——规则算法在 862 张老设备图像上” 四边均 ≤ 4 px” 的命中率为 94%，在 89 张新设备图像上为 93%（**此处” 四边” 指第一阶段输出的成像窗口四条边**，真值为人工确认的窗口；曾最费手的右边界在这 89 张上从改进前的 26% 提升到 97%，改进前中位偏差为偏宽 71 px），**且无需任何训练数据**；
- **上下边界**由组织回声决定，是模糊的语义量，必须靠学习。

若把两者交给同一个网络，网络的容量会被” 左右边界很好学” 这一简单任务占据，反而削弱对上下边界的拟合能力。因此采用**分而治之**：规则负责确定性几何，网络负责模糊语义。这一范式与 Faster R-CNN 的” 区域提议 + 框内细化” 同构[6]，也与近期 DDH 领域的标准切面识别工作思路一致[7]。

2.2　第一阶段：成像窗口定位

2.2.1　核心判据：为什么不用亮度阈值

最直接的想法是用亮度阈值区分成像区与黑边。实测否定了这条路：**成像区内部存在大片无回声暗区**，其灰度均值与黑边接近（甚至为 0），亮度阈值会把它们判成黑边。

真正稳定可分的是**” 是否纯黑”**——黑边像素恒等于 0，而成像区即使最暗处也总有相当比例的像素大于 2/255（实测深部暗区的非纯黑占比为 0.36–0.88）。判据取

$$\text{content}(x,y)=\begin{cases}1, & I(x,y)>\tau_0,\\ 0, & \text{otherwise},\end{cases}\qquad \tau_0=2/255. \tag{1}$$

为避免逐像素噪声，把二值图按 4×4 块聚合，块内非纯黑占比超过 $\tau_b=0.05$ 则该块记为内容。**必须先做像素级判定再聚合到块**：缩放会把暗区稀疏斑点平均掉，导致深部内容被误判为黑边——这正是早期版本的失败原因。

2.2.2 五步流程与真实中间结果

定位算法分五步，图 3 给出了**同一张截图的真实中间结果**，每一步都可肉眼核对：

1. **块级内容掩膜**：按上述纯黑判据生成 4×4 块级二值图；
2. **水平开运算**（$r=1$）：要求一个块在左右各 1 块内都连续存在才保留，删除深度标尺刻度点、TGC 指示条这类 1–2 块宽的竖细结构；
3. **二维闭运算**（$r=2$）+ **连通域标记**：填补小块空洞，用两遍扫描加并查集取面积最大连通域的外接框；
4. **块坐标还原**：把粗框的 4×4 块坐标乘 4 换回像素坐标（`box = [x0*BLOCK, ...]`）；
5. **黑走廊判据 + 像素级梯度吸附**：**在上一步得到的像素坐标上**做走廊扫描与 ±12 px 吸附，把边界从块精度细化到像素精度（详见 2.2.3）；
6. **输出最终窗口**：得到纯成像区。

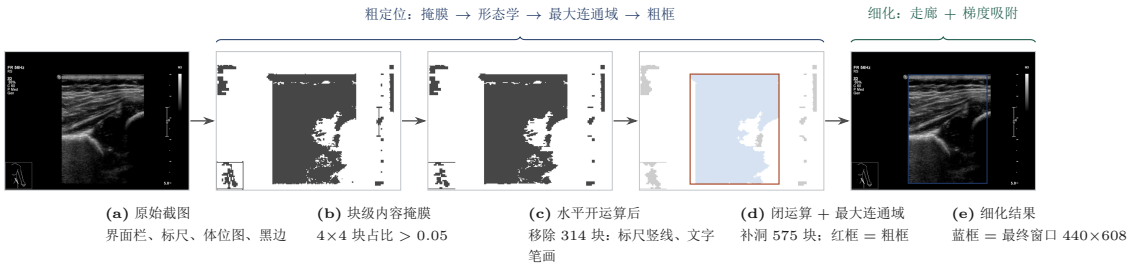


图 3 成像窗口定位全过程（真实中间结果，同一张截图）。(a) 原始截图；(b) 块级内容掩膜；(c) 水平开运算后，标尺竖线与文字笔画被移除 314 块；(d) 闭运算后补洞 575 块，浅蓝为最大连通域，红框为粗框；(e) 走廊判据与梯度吸附后的最终窗口

开运算必须在闭运算之前。若顺序颠倒，稀疏的标尺点会先被膨胀成横贯的桥，把成像区与右侧界面连成一整块，之后再无法分开（实测最大连通域右边界会被拖到 $x=984$，而真实内容止于 $x=864$）。

2.2.3 边界细化：黑走廊 + 像素级梯度吸附

各型号设备的版式有一个共同结构：**成像内容 → 一条黑走廊（窗外）→ 才是界面元素**。由此可以只判断”边在哪”，而不必把” 内容” 与” 界面” 用阈值分开。

算法从内容内部（占用率最高的一列）向两侧逐列扫描，遇到**连续 $\geqslant 2$ 列占用率低于** $\tau_{\text{low}}=0.35$ 即判定进入走廊，该处为粗边界；再在 ±12 px 邻域内，以” 跨边界两侧各 4 px 的平均占用率之差最大” 为准做**像素级吸附**。

之所以必须分层，是因为**任何静态阈值都分不开两者**：老设备窗口右缘本身是渐隐的（占用率 0.36–0.57），与 TGC 条（0.37–0.41）数值完全重叠，如图 4 下半部分所示。走廊法把界面元素挡在走廊之外，只负责” 边在哪”；吸附负责” 精确到哪一列”。扫描前还需对剖面做 **3 列中值滤波**：走廊里常夹着标尺短横这类单列亮点，会打断” 连续低列” 计数，使走廊起点晚判 5–8 px；而内容断崖处（1.00 → 0.08）中值几乎不动。

2.2.4 上下边界、参数标定与拒识

上下边界改为**从粗框外缘向内扫描**，取第一条非纯黑占比超过 $\tau_e=0.20$ 的行。方向很关键：窗口底部有一条很暗的窄带（行灰度仅 0.6–7.8），若从内容深处向外游走会被它截断；而窗外文字行的占用率只有 0.03–0.08，低于阈值不会被误选。全部关键参数见表 2。

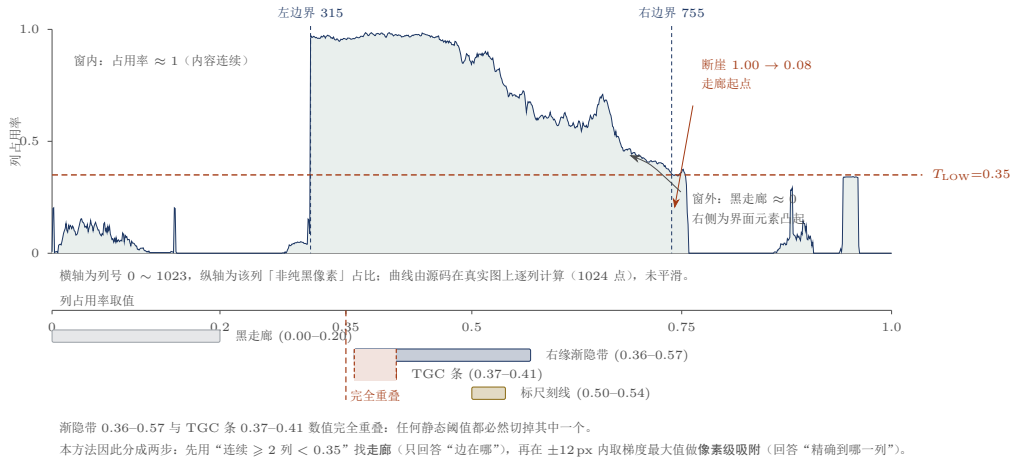


图 4　走廊判据的必要性。上：真实截图的逐列占用率剖面（1024 个采样点），窗内平台 ≈ 1、边界断崖、窗外走廊 ≈ 0；下：窗口右缘渐隐带与 TGC 条的取值区间完全重叠，静态阈值必然误伤其一

参数	作用	取值
τ_0	像素级纯黑判据	2/255
τ_b	块级内容占比阈值	0.05
τ_{low}	走廊判据：连续低列阈值	0.35
τ_e	行级端点判据	0.20
中值滤波窗	抑制标尺单列亮点	3 列
吸附搜索半径	像素级边界细化	±12 px

表 2　窗口定位的关键参数（均由实测标定）

拒识机制：面积占比越界（$< 5\%$ 或 $> 95\%$）、第二大连通域超过最大域的 25%（拼图/双屏）、窗口贴图像边界，均标记为可疑；窗口之外若仍有一整片实心内容（占用率 > 0.5 且连续 5 块），追加 `content_beyond_*` 标记。**系统宁可标记可疑，也不静默输出错误裁剪。**

2.3　第二阶段：CropNet 边界回归

2.3.1　输入预处理与网络结构

窗口裁出的图像长宽比悬殊，而网络要求固定输入。若直接拉伸，解剖结构会变形、边界位置随之偏移；因此采用 **letterbox**：按 $s = \min(384/w, 384/h)$ 等比缩放后居中补黑，同时记录真实内容在 384×384 画布中的位置 $[p_x, p_y, p_x{+}n_w, p_y{+}n_h]$，供后续 ROIAlign 使用。

2.3.2　为什么取 Layer3：感受野与分辨率的折中

主干采用 ImageNet 预训练的 ResNet-18[2]，**只取到 layer3**，其 $256 \times 24 \times 24$ 的特征图进入边界分支。

这一取舍由两个约束共同决定：**要定位的是”第几行”，既要求看得见足够上下文，又要求分辨率够细。**按感受野递推实测（只计主干支路）：Layer1 为 43 px、Layer2 为 99 px、Layer3 为 211 px、Layer4 为 435 px——**只有 Layer4 超过输入高度 384 px**；但 Layer4 的纵向只有 12 格，一格代表 32 px，边界会明显跳变，而 Layer3 纵向 24 格、一格 16 px。**实测 Layer3 与 Layer4 的定位精度无显著差异（$p = 0.8678$），因此在”分辨率更细、算力更低”的一侧选 Layer3：再深一层牺牲分辨率，再浅一层语义不足，24×24 是折中点。**

2.3.3　多层级融合：理论上更优的下一步

一个自然的追问是：**只取 layer3 是否浪费了浅层信息？**

理论上，**融合 Layer1+2+3 更合理**。Layer3 的 24×24 特征图上纵向一格为 16 px，对边界定位偏粗；而 Layer1 输出 96×96（总步幅 4），一格为 4 px，保留了更细的纵向位置信息；把浅层的精细位置与深层的抽象语义结合，理论上应优于单层。这一推断有实验支撑但**未达统计显著**：在 **ResNet-18 上，L1+2+3 融合把 3% 容差合格率从 51.1% 提升到 56.8%（+5.7 个百分点，McNemar $p = 0.3323$）**，上边界均值从 17.39 px 降到 16.97 px（$p = 0.8908$）——**方向一致向好，但幅度在噪声范围内。**

需要如实说明的是：该提升在当前 88 张测试集上**未达统计显著**（上边界 $p = 0.89$，合格率 McNemar $p = 0.33$）。因此目前**生产环境部署的仍是单层 layer3 模型**，融合版本作为已验证的候选方案，将在扩大测试集后重新评估——若后续数据证实，可直接替换，无需改动系统其他部分。

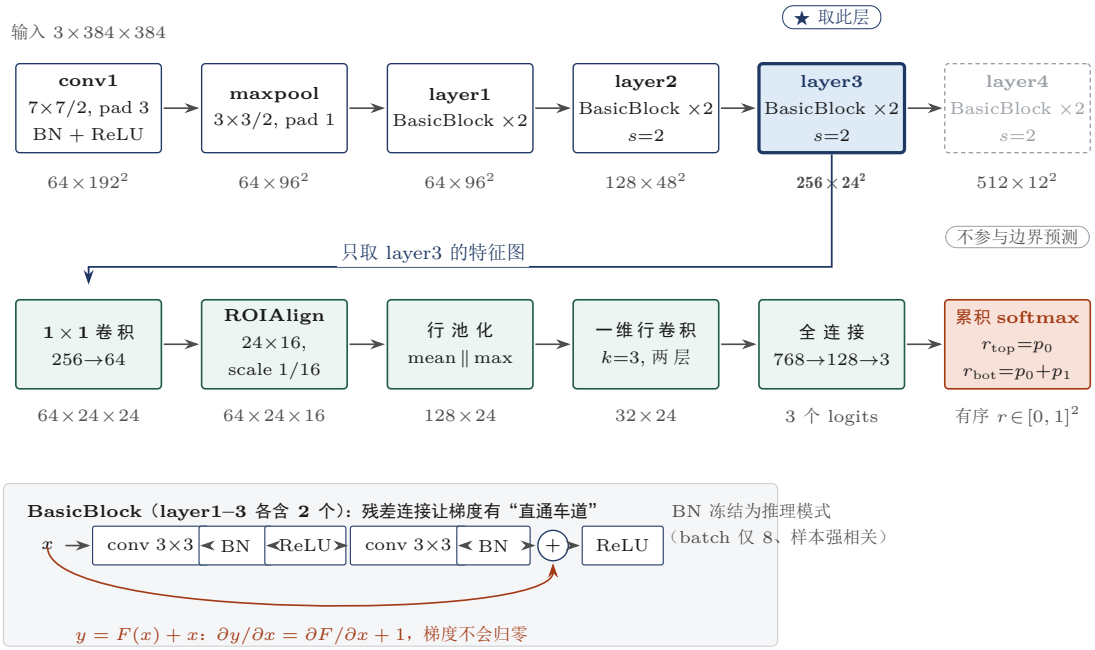


图 5 CropNet 结构与张量形状。主干逐级降采样至 layer3 的 256 × 24 × 24；边界分支经 1 × 1 投影、ROIAlign[3]、行池化、一维行卷积与全连接输出三个 logits。左下为 BasicBlock 的残差结构

2.3.4 行向量化与一维行卷积

上下边界只与” 行” 有关，宽度方向是干扰，因此先用 ROIAlign 把真实内容区域双线性采样成固定 24×16 网格——相比 RoIPool 的量化取整，ROIAlign 用浮点坐标插值，无像素级错位。随后对每一行的 16 个值分别取均值与最大值，拼接成 128 维行向量：

$$\mathbf{r}_j = \big[\,\mathrm{mean}_c \mathbf{F}[c,j,:] \,\big\|\, \max_c \mathbf{F}[c,j,:]\,\big] \in \mathbb{R}^{128}, \qquad j = 1,\dots,24. \tag{2}$$

均值反映整体强度、最大值保留强响应，两者互补。接下来沿高度方向做一维卷积，让相邻行互相参考：

$$\mathbf{y}_j = \mathrm{ReLU}\Big(\sum_{\delta=-1}^{+1} \mathbf{W}_\delta\, \mathbf{r}_{j+\delta} + \mathbf{b}\Big), \qquad k=3,\ \texttt{padding}=1. \tag{3}$$

$k=3$、padding= 1 保证输出长度仍为 24，两层堆叠后感受野从 3 行扩到 5 行（图 6）。关键在于：判断第 j 行是否为边界，不能只看第 j 行，而要看第 $j-1$ 至 $j+1$ 行的上下文；一维卷积只在行序列上滑动，**不会像二维卷积那样同时混入宽度方向的信息**。输出 32×24 展平为 768 维送入全连接头。

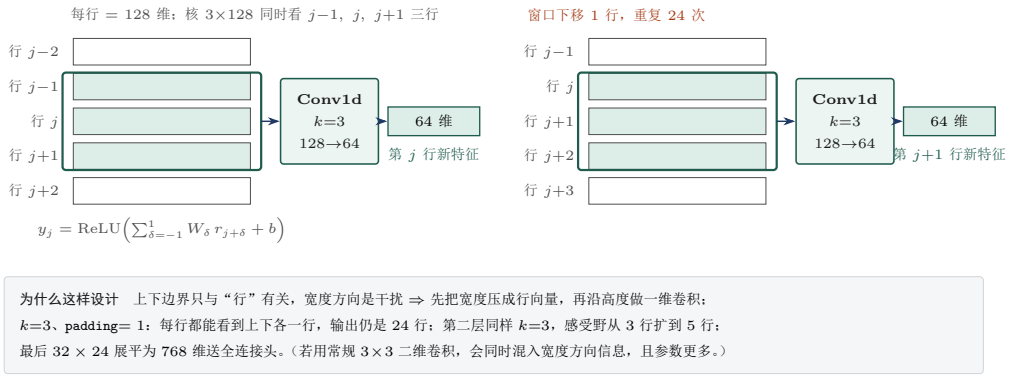


图 6 一维行卷积的逐行计算过程。左：计算第 j 行时卷积核覆盖第 $j-1$、j、$j+1$ 行；右：窗口下移一行，输出第 $j+1$ 行的新特征

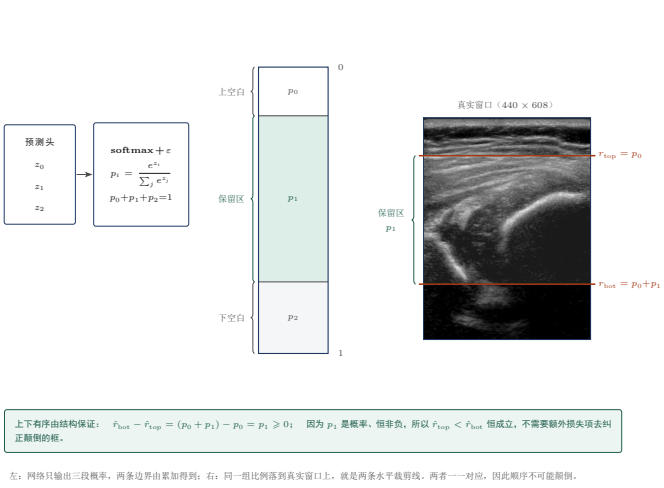
2.3.5 累积 softmax：有序性由结构保证

若直接回归 $(\hat{r}_{\mathrm{top}}, \hat{r}_{\mathrm{bot}})$，训练早期极易输出上下颠倒的非法解，只能靠额外损失项纠正。本文改为输出 3 个 logits，softmax 得到三段概率后**累积求和**：

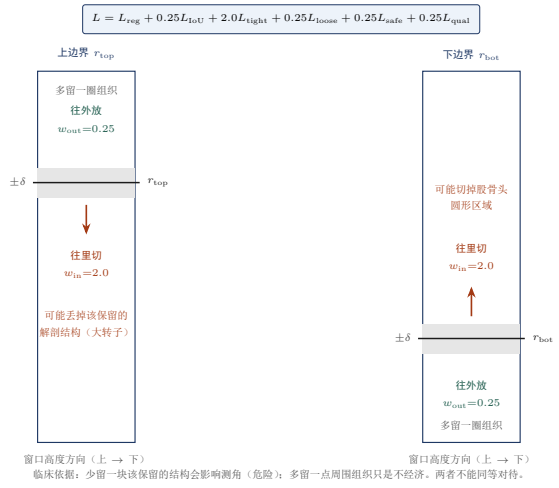
$$p = (1 - 3 \times 10^{-4}) \cdot \mathrm{softmax}(\mathbf{z}) + 10^{-4}, \qquad \hat{r}_{\mathrm{top}} = p_0, \quad \hat{r}_{\mathrm{bot}} = p_0 + p_1, \tag{4}$$

$$\hat{r}_{\mathrm{bot}} - \hat{r}_{\mathrm{top}} = (p_0 + p_1) - p_0 = p_1 \geqslant 10^{-4} > 0. \tag{5}$$

几何上，把窗口高度视为 $0 \sim 1$ 的线段，三段正好分成”上空白 / 保留区 / 下空白”。由于 softmax 各项非负、且整体又加了 10^{-4} 的平滑下界，故 $p_1 \geqslant 10^{-4} > 0$ 严格成立，$\hat{r}_{\mathrm{top}} < \hat{r}_{\mathrm{bot}}$ **恒成立**——上下顺序由输出结构保证，而非靠损失惩罚出来。



(a) 累积 softmax：有序性由结构保证。网络只输出三段概率，两条边界由累加得到



(b) 非对称损失：向内过裁的惩罚是向外欠裁的 8 倍

图 7　两处”把约束写进结构”的设计。(a) 累积 softmax 使上边界必然小于下边界，顺序不可能颠倒；(b) 容差带之外，往内裁与往外裁被赋予 8 倍惩罚差，把”宁可多留不可切掉”的临床直觉变成可优化的数学目标

这一改动的收益在训练早期最明显：直接回归时前几个 epoch 有相当比例样本输出非法框，梯度方向被这些样本带偏；改成累积 softmax 后，非法框从结构上不再可能出现，损失曲线也更平滑，省掉了”额外加一项惩罚”的调参工作。

2.3.6　非对称损失：把临床优先级编码进目标函数

临床上，把边界往**内**裁（少留、切掉该保留的成像区结构）比往**外**留（多留一圈周围组织或黑边）严重得多：**少留一块该保留的结构会影响测角，多留一圈只是不经济**。为此对两个方向分别按不同权重惩罚，且**容差带之内不惩罚**。记标注上、下边界为 $\ell_{\mathrm{top}}, \ell_{\mathrm{bot}}$，预测为 $\hat{r}_{\mathrm{top}}, \hat{r}_{\mathrm{bot}}$，容差 δ（取窗口高度的 4%），则

$$\begin{aligned}\mathcal{L}_{\mathrm{asym}} = \frac{1}{N}\sum_i \Big[\, & w_{\mathrm{in}} \cdot \big(\max(0, \hat{r}_{\mathrm{top}} - \ell_{\mathrm{top}} - \delta) + \max(0, \ell_{\mathrm{bot}} - \delta - \hat{r}_{\mathrm{bot}})\big) \\ & + w_{\mathrm{out}} \cdot \big(\max(0, \ell_{\mathrm{top}} - \delta - \hat{r}_{\mathrm{top}}) + \max(0, \hat{r}_{\mathrm{bot}} - \ell_{\mathrm{bot}} - \delta)\big)\Big],\end{aligned} \tag{6}$$

第一行两项是**向内过裁**（上边界往下切、下边界往上切），第二行两项是**向外欠裁**。

其中 $w_{\mathrm{in}} = 2.0$、$w_{\mathrm{out}} = 0.25$。**关键在于这两个方向是靠 $(\hat{r} - \ell)$ 的符号区分出来的，不是在同一个绝对误差上加分段权重**：δ 之内的偏差被 $\max(0, \cdot)$ 截成 0，因此**落在容差带内的样本损失恰为 0**；只有越过容差带、且方向不同时才分别计入。图示满窗高度 1、$\delta = 0.04$ 时，**向内过裁 0.11 产生损失 0.44，向外欠裁同样 0.11 只产生 0.055——相差 8 倍。这把”宁可多留一点黑边，也不能切掉成像区”的临床直觉，变成了可优化的目标函数**。

3　系统实现

本系统以 **Windows 离线客户端**形式交付，不依赖网络、不上传任何患者图像——这对医疗数据合规很关键。设计目标很朴素：**让前面两章的算法能被真正用起来**。

3.1　主干功能与界面

界面围绕”批量、可见、可干预”三个原则，对应三项主干功能：**批量导入导出**（一次导入整个文件夹，结果按原文件名自动保存，这是 77 倍提速真正兑现的地方）、**并排预览**（原图与成品同屏对照，预测边界直接画在图上）、**人工可干预**（可拖动边界、重设窗口、恢复预测或标记”稍后处理”——**人在回路，但工作量从”全做”降为”核对”**）。



图 8　客户端主界面（预览对比模式）。左侧为文件夹清单与批量进度，中部左为原图、右为裁剪成品，右侧为一键导出

3.2　两种工作模式

系统提供**逐张审核**与**批量直出**两种模式：前者适用于构建标注数据集与疑难样本，每张确认后可微调边界；后者适用于已有大批量图像、模型已可信的场景，一键处理整个文件夹。两者单张耗时不同——**逐张审核**约 1–1.5 s/张，**批量直出**约 0.2 s/张。第 1.5 节报告的 77 倍提速对应**批量直出**；若采用逐张审核模式，提速约为 10–15 倍，这一点如实说明。

3.3　数据闭环

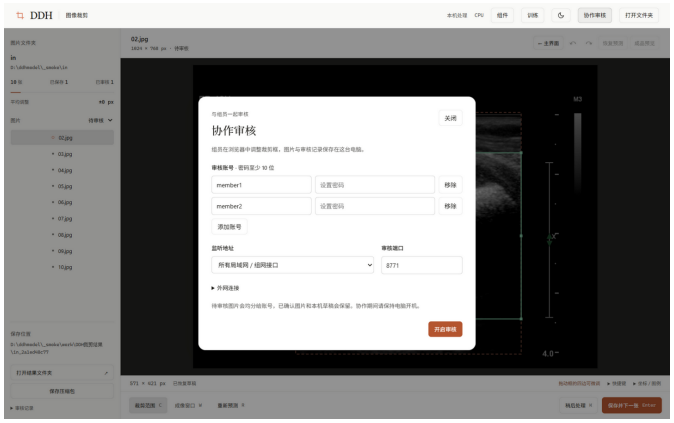


图 9　协作审核界面。裁剪结果可被多人复核、标记与留痕，形成”标注—训练—复核”的数据闭环

系统记录每张图的处理痕迹（谁审、何时、是否修改边界）。这一机制的价值不只在质量控制：**人工修正的结果可直接回流为新的训练样本**。第 5.5 节已表明标注质量是当前突破方向，而这套闭环正是持续提升标注质量的基础设施。

4　研究方法

4.1　数据集与评价指标

数据：项目累计标注 1 550 张真实超声图像（老批次 862 张 + 三成员新标注 688 张），覆盖三种设备型号。**本节 6 组配置的对照实验在其中的 862 张老批次图像上完成**——该子集标注口径与窗口标签统一，按 560 / 128 / 86 / 88 划分为训练/验证/校准/测试集，并**固定划分、固定随机种子（seed=42）**以保证所有配置可比。

指标：

- 上下边界误差（像素，越小越好）；
- 纵向 IoU（上下边界区间的重合度，越大越好）；
- 容差合格率（误差在窗口高度 2%/3%/5% 以内的比例）。

4.2 选型的双重依据：文献 + 自证实验

模型选型不能只凭” 大的应该更好” 的直觉。我们采用**外部文献 + 自有实验**的双重论证。

4.2.1 外部依据：同类任务上 ResNet-50 的收益是边际的

Lawley 等 2024 年在**超声**图像上系统对比了 9 种网络（含 ResNet-18/34/50/101/152），每种训练 20 次取最优[8]。

其中 ResNet-18 与 ResNet-50 的对照最有参考价值：参数量分别为 1118 万与 2354 万（**2.1 倍**），在完整数据 + 迁移学习下精度为 83.04% 与 83.48%——**仅差 0.44 个百分点**；而在小样本（800 张）下为 67.41% 与 73.21%（差 5.80 个百分点）。**数据越少，模型容量的差异反而越明显**。

该文的核心结论是：**” 数据集规模对精度的影响比网络选择更重要”**（*Dataset size proved a more important factor in determining accuracy than network selection*）。

对我们的启示很直接：**当参数量翻倍只换来 0.44 个百分点的提升时，是否值得为它付出 2 倍的训练与推理成本，取决于本任务能否测出这 0.44**。这必须由实验回答。

4.2.2 自有实验：6 组同条件对照

我们在**同一测试集（88 张）、同一划分、同一随机种子**上训练并评估了 6 组配置，覆盖两个维度：

编号	配置	主干	特征使用
A1	`r18_l3`	ResNet-18	仅 Layer3
A2	`r50_l3`	ResNet-50	仅 Layer3
B1	`r18_l123`	ResNet-18	Layer1+2+3 融合
B2	`r50_l123`	ResNet-50	Layer1+2+3 融合
C1	`r18_l4`	ResNet-18	仅 Layer4
C2	`r18_l1234`	ResNet-18	Layer1+2+3+4 融合

表 3 6 组对照实验的配置设置

统计方法：对每一组对比做**配对 Wilcoxon 符号秩检验**（$n = 88$ 张测试图，逐图配对），并以 5 000 次配对 bootstrap 给出 95% 置信区间。选择配对检验是因为同一张图在不同配置下的误差并非独立——配对能消除图像难度差异带来的方差。

5 实验结果与讨论

5.1 主结果：6 组配置的精度对比

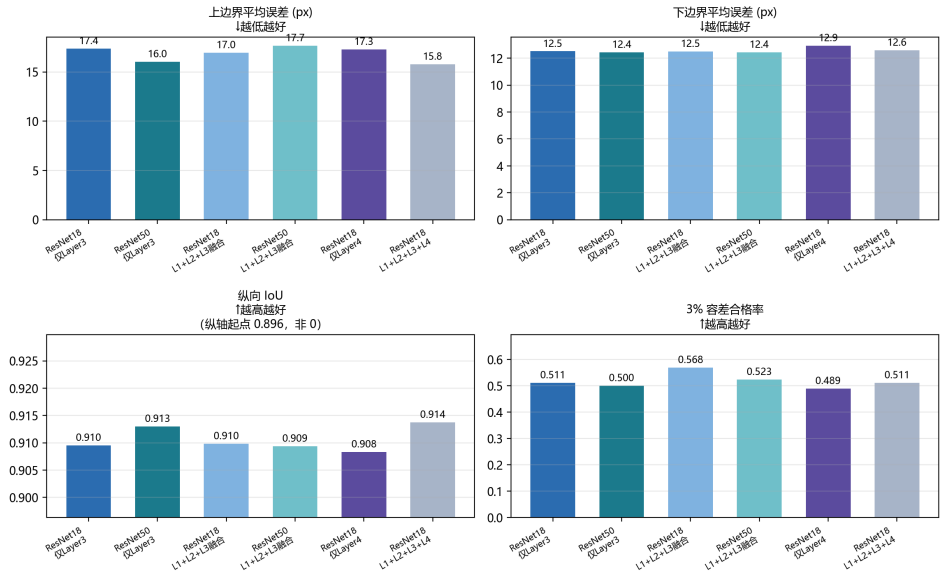


图 10 6 组配置在同一测试集（88 张）上的裁剪精度对比

表面上看，不同配置之间的数字确有差异。但**统计检验表明这些差异绝大多数不显著**。

表 4　6 组配置的精度与成本汇总（测试集 88 张）

配置	上边界均值 (px)	下边界均值 (px)	纵向 IoU	3% 合格率	参数量 (M)	模型大小 (MB)	CPU 推理 (ms)
r18_l3	17.39	12.51	0.9096	51.1%	11.37	43.5	30.7
r50_l3	16.03	12.44	0.9130	50.0%	23.75	90.9	78.5
r18_l123	16.97	12.50	0.9098	56.8%	11.41	43.6	33.2
r50_l123	17.66	12.44	0.9094	52.3%	23.88	91.4	81.6
r18_l4	17.30	12.92	0.9083	48.9%	11.41	43.6	31.7
r18_l1234	15.77	12.59	0.9138	51.1%	11.45	43.8	33.9

5.2　关键发现一：换主干、加深层都没有显著收益

对比	上边界 p	下边界 p	IoU p	3% 合格率 p	结论
ResNet-18 vs 50（仅 L3）	0.0805	0.9469	0.2165	1.0000	均不显著
ResNet-18：L3 vs 融合	0.8908	0.8842	0.9635	0.3323	均不显著
ResNet-50：L3 vs 融合	**0.0398**	0.7582	0.3002	0.8036	未校正负向
ResNet-18：L123 vs L1234	0.0912	0.6264	–	–	不显著

表 5　四组配对 Wilcoxon 符号秩检验结果（$n = 88$）

四组对比中，按 4×2 共 8 次比较做 Bonferroni 校正（$\alpha/8 = 0.00625$）后**没有任何一项达到显著**；未校正的名义水平下只有一项低于 0.05，且是**负向**的：在 ResNet-50 上启用多尺度融合，上边界误差从 16.03 px 增加到 17.66 px（$p = 0.0398$，Bonferroni 校正后 $p = 0.1592$）。**因此这一项应表述为" 在未校正的名义水平下呈负向趋势"，而非" 显著变差"**——本报告不对任何单项结论作显著性宣称。

为什么在 ResNet-50 上融合反而有害？我们的解释（推测，待进一步验证）是：ResNet-50 的 layer3 已有 1 024 通道，语义容量本身充足，再拼接 Layer1/2 的低层特征反而在 560 张的小训练集上稀释了高层语义、增加了优化难度；而 ResNet-18 的 layer3 只有 256 通道，容量紧张，低层信息才是有效补充。**这说明融合的收益取决于主干容量，不能一概而论。**

5.3　关键发现二：成本是确定的，收益是不确定的

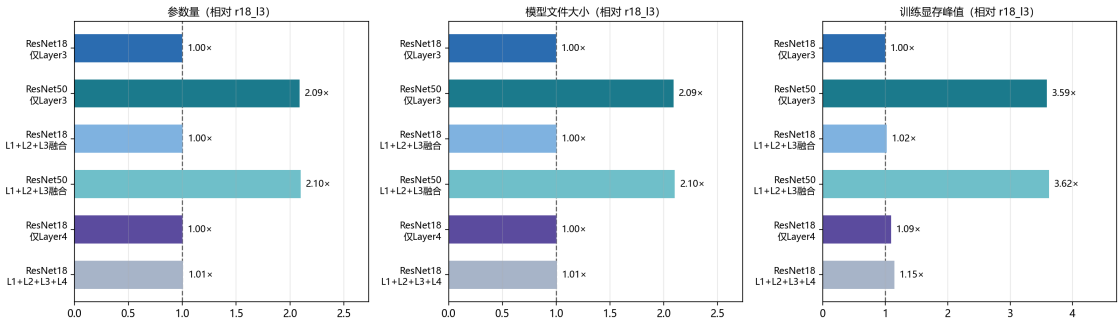


图 11　6 组配置的计算成本对比（参数量与模型大小为确定性量；**显存与 CPU 耗时为当前软硬件环境下重复测得**，随机器配置变化）

ResNet-50 相对 ResNet-18 的成本是**可精确测度的**：参数量 2.09 倍（11.37M → 23.75M）、模型文件 2.09 倍（43.5 → 90.9 MB）、训练显存峰值 3.59 倍（622 → 2 232 MB）、**CPU 推理约 2.5 倍**（三组重复实测：r18_l3 为 30.36/30.77/30.95 ms，r50_l3 为 77.72/78.15/79.51 ms；**中位数之比 78.46/30.69 = 2.56**）。

而它带来的精度收益是**不显著的**（IoU $p = 0.2165$）。**用确定的两倍成本，去换一个测不出的收益，这不划算。**

结论：确定 **ResNet-18 + Layer3** 为当前方案。**这一选择是成本—精度权衡的结果**（在精度无可测差异的前提下，选参数量仅为一半、CPU 约 2.5 倍更快的那个），而非" 更大的网络一定更好或一定更差" 的普适判断。Lawley 等[8] 在**腹部超声 16 类分类**任务上观察到" 数据规模比网络选择更关键"，与本研究**方向一致；但该文任务、数据与指标均与本研究不同，不构成对本任务的直接验证，也不能据此断言" 我们在本任务上无需再调网络"**。

5.4　讨论一：为什么是 Layer3，而不是 Layer4

一、感受野实测（ResNet-18，输入 384×384）。按 $r_l = r_{l-1} + (k_l - 1)\, J_{l-1}$ 逐层递推，且**只统计主干支路**（残差支路的 1×1 降采样卷积不扩大感受野，误计入会使感受野虚高约 4 倍）：Layer1–4 依次为 **43 / 99 / 211 / 435 px**。只有 **Layer4（435 px）首次超过输入高度 384 px，Layer3 仅覆盖约 55%**。

二、加深并没有换来精度。我们最初推导认为 Layer4 特征图仅 12×12、量化误差下界 $s/2 = 16\,\text{px}$ 必然超标，**但对照实验否定了它：**`r18_l4` 上边界中位误差实测 **12.0 px**，与 `r18_l3` 的 11.2 px 无显著差异（$p = 0.8678$）。**三、结论。**既然” 覆盖全图” 的 Layer4 与” 只覆盖 55%” 的 Layer3 精度无可测差异，说明**对本任务而言感受野是否覆盖全图并非精度决定因素**——输入已在第一阶段裁成纯成像区，解剖上下文在局部与全局尺度上高度自相似。选 Layer3 是**成本—精度权衡**（24×24 而非 12×12，纵向分辨率更细、算力更低），**而非”Layer4 不可能” 或”Layer3 已全局”**。

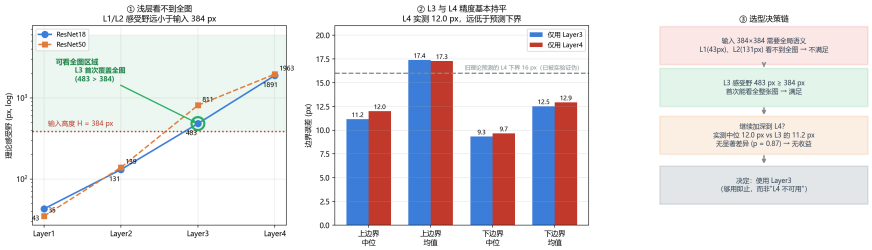


图 12　层级选择论证：左为感受野随深度增长（Layer1–4 依次为 43/99/211/435 px，仅 Layer4 超过输入高度 384 px）；中为 Layer3 与 Layer4 的实测精度对比，L4 远低于旧理论预测的下界；右为决策链

5.5　讨论二：真正的突破在数据，不在模型

这是本次实验最有价值的发现。

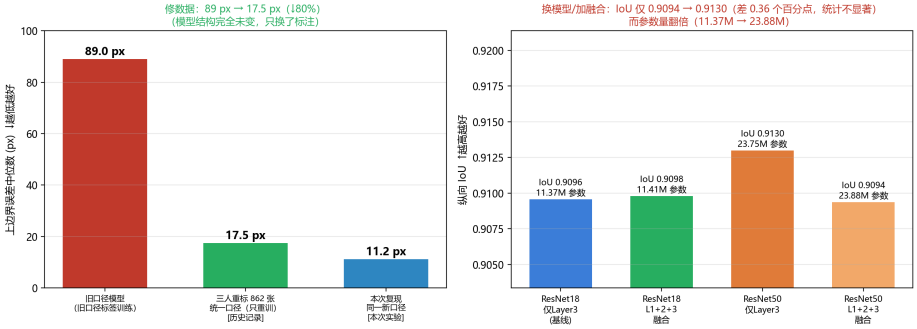


图 13　提升精度的两条路：修数据（左）远比换大模型（右）划算

路径	精度变化	是否显著	代价
统一标注口径	上边界**中位数** 89 px → 17.5 px（**↓80%**）	–	人力标注
换 ResNet-50	IoU +0.0034	否（$p = 0.22$）	参数 2.09×、推理 2.4×
加多尺度融合	3% 合格率 +5.7 pp	否（$p = 0.33$）	参数 +0.36%
改用 Layer4	无变化	否（$p = 0.87$）	–

表 6　提升精度的两条路线对比

模型结构完全未变、只把标注口径统一之后，上边界误差**中位数**从 89 px 降到 17.5 px，**降幅 80%**——这是项目历史对照（旧口径 vs 新口径模型，同一测试集 88 张）。本次复现的新口径模型（表 4）上边界误差**均值 17.39 px、中位数 11.2 px**。**这两组数字不构成” 口径已被验证正确” 的证据：**历史记录 17.5 px 是中位数，本次为 11.2 px（低约 36%），二者统计量与训练细节的一致性无法从现有记录完全确认。**唯一确定的是量级关系：口径修正带来的改善（89 → 17.5，约 5 倍）远大于任何结构改动（均在 1 个百分点或几个像素内）**。这与” 图像质量与标准化对测量一致性的影响往往大于模型选择” 这一普遍认识[9] 相符。**实践含义：把时间投入提高标注质量，比投入换更大模型，回报高得多。**

5.6　不足与改进方向

我们如实列出四点局限：

1. **人工标注标准难以机械性统一**。不同标注者对” 成像区上边界该切在哪里” 的判断存在细微差异，同一人在不同时间也会漂移；这类分歧靠算法消除不掉，需更明确的规范与多人交叉校验来收敛。目前**尚未计算标注者间一致性指标**（如 ICC），这是该局限的直接量化缺口。
2. **图像数量仍然有限**。本节对照实验使用的 862 张（训练集 560 张），是本轮所有” 不显著” 结论的直接背景；要验证多层级融合这类小幅改进，需要把数据量提上去。

3. **特殊 DDH 图像尚未充分适配**。部分截图的成像区内含无关文字与婴儿体位示意图，会被误当作成像内容，影响窗口定位与边界判断。系统目前用拒识标记把它们标为可疑，但**还没有做到良好的算法适配**，这是后续重点。
4. **尚未验证裁剪对测角精度的影响**。本文的 2%/3%/5% 是**按窗口高度定义的工程阈值**，不是临床强制标准；项目**也尚未测量裁剪前后 Graf α/β 角的实际差异**。因此本文的结论止于" 裁剪质量"，**不能外推为" 已证明可提升临床测角一致性"**——这一环节需与临床合作方共同验证。

进一步的工作：把特殊版式纳入窗口定位设计，并扩大数据规模、完善标注规范，让小幅改进也能被统计检验出来。

6 创新性说明

6.1 问题定位：补上被忽视的前置环节

现有 DDH 人工智能研究集中在**分型、测角、标准切面识别**等下游任务[5]，而**进入这些任务之前必需的图像裁剪环节长期被忽略**。本项目明确聚焦这一空白环节，将其定位为" 为 Graf 分型及后续研究做前置准备"。这一定位的价值在于：**上游图像不规范，下游再好的模型也会被拖累**。

6.2 方法设计：按误差性质拆分，让规则与学习各司其职

我们没有采用" 一个网络端到端搞定" 的常见做法，而是按**误差性质**拆分任务：

- **左右边界**是确定性几何量 → 交给规则算法，**无需训练、零样本可用、行为可解释**；
- **上下边界**是模糊语义量 → 交给神经网络回归。

这一设计的实际收益是：第一阶段不需要任何标注数据即可工作，**显著降低了冷启动成本**；同时规则部分失败模式可枚举，便于临床审计。而在网络内部，我们又做了两处" 把约束写进结构" 的设计：

- **有序性由结构保证**：用**累积 softmax** 把上下边界表示为三段概率的累积和，使 $y_{\text{top}} \le y_{\text{bot}}$ 恒成立，**从结构上消除了非法输出**，无需后处理修正；
- **临床优先级写进目标函数**：非对称损失以 $w_{\text{in}}/w_{\text{out}} = 8$ 的比例惩罚**向内过裁**与**向外欠裁，把" 宁可多留一点黑边，也不能切掉成像区" 这一临床直觉，从口头约定变成了可优化的数学目标**。

6.3 实验结论：用对照实验指出真正的突破口

本次工作最有价值的产出，可能不是某个具体模型，而是一组**同等条件下的否定性结果**：在 560 张训练图的规模下，**换主干、加深层、多层级融合都没有产生统计显著的收益，而标注口径的统一带来误差显著下降**。该结论有 6 组同条件对照实验支撑，与文献[8]" 数据规模比网络选择更关键" 的观察**方向一致**（任务不同，不构成直接验证）。**结论边界须同时说明**：单一随机种子、88 张测试集、无多种子重复与预注册——它是" 当前样本下未检出显著差异"，而非" 已证明这些改动无效"。

参考文献

[1] Graf R. Classification of hip joint dysplasia by means of sonography[J/OL]. Archives of Orthopaedic and Traumatic Surgery，1984，102（4）：248-255. DOI:10.1007/BF00436138.

[2] He Kaiming，Zhang Xiangyu，Ren Shaoqing，et al. Deep residual learning for image recognition[C/OL]//2016 IEEE conference on computer vision and pattern recognition（CVPR）. Las Vegas，NV，USA：IEEE，2016：770-778. DOI:10.1109/CVPR.2016.90.

[3] He Kaiming，Gkioxari G，Dollár P，et al. Mask R-CNN[C/OL]//2017 IEEE international conference on computer vision（ICCV）. Venice，Italy：IEEE，2017：2980-2988. DOI:10.1109/ICCV.2017.322.

[4] 中华医学会骨科学分会关节外科学组. 中国发育性髋关节发育不良诊疗指南（2023 版）[J/OL]. 中华解剖与临床杂志，2023，28（8）：493-511. DOI:10.3760/cma.j.cn101202-20230612-00145.

[5] Bhavsar S，Gowda B B，Bhavsar M，et al. Artificial intelligence to detect developmental dysplasia of hip：a systematic review [J/OL]. Journal of Paediatrics and Child Health，2025，61（11）：1712-1727. DOI:10.1111/jpc.70172.

[6] Ren Shaoqing，He Kaiming，Girshick R，et al. Faster R-CNN：towards real-time object detection with region proposal networks [C/OL]//Advances in neural information processing systems 28（NIPS 2015）. Montreal，Canada：Curran Associates，2015：91-99. https://papers.nips.cc/paper/2015/hash/14bfa6bb14875e45bba028a21ed38046-Abstract.html.

[7] Ahn K-S，Choi J H，et al. Deep learning-based automated guide for defining a standard imaging plane for developmental dysplasia of the hip screening using ultrasonography：a retrospective imaging analysis[J/OL]. BMC Medical Informatics and Decision Making，2025，25（1）：91. DOI:10.1186/s12911-025-02926-8.

[8] Lawley A，Hampson R，Worrall K，et al. Analysis of neural networks for routine classification of sixteen ultrasound upper abdominal cross sections[J/OL]. Abdominal Radiology，2024，49（2）：651-661. DOI:10.1007/s00261-023-04147-x.

[9] 于静淼，吕学敏，陈涛，等. 发育性髋关节发育不良超声检查指南质量控制要点分析[J/OL]. 中华医学超声杂志（电子版），2021，18（7）：634-637. DOI:10.3877/cma.j.issn.1672-6448.2021.07.003.